

Multiagentní systémy s ChatGPT a knihovnou LangGraph

Michal Vašinek

Odborný asistent, katedra informatiky FEI, VŠB-TUO

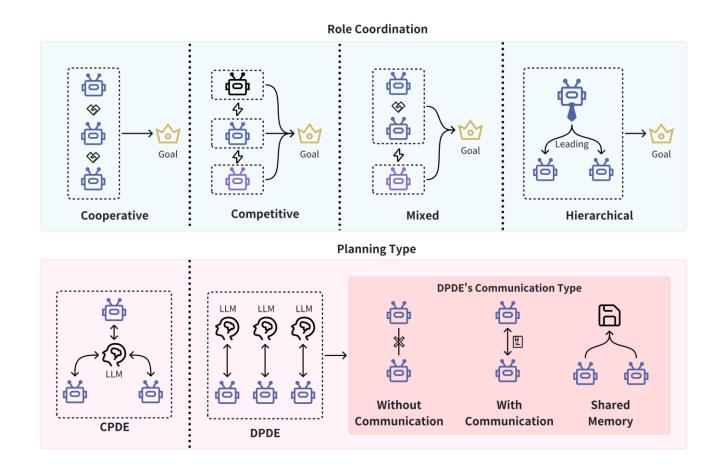


Multiagentní systémy

Multiagentní systém (MAS)

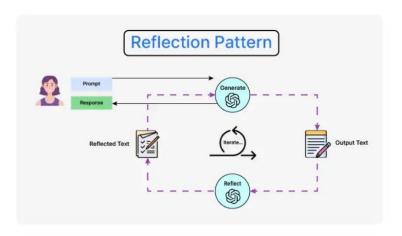
- MAS je kolekcí autonomních agentů, kteří spolupracují a komunikují.
- Vývoj od počátku 70 let, především v oblasti robotiky.
- Agenti jsou schopni přijímat zprávy z okolí, rozhodovat se a provádět akce.
- Agent nemusí být nutně počítačem řízený objekt.
- Různí agenti dostávají zodpovědnost za různé činnosti.

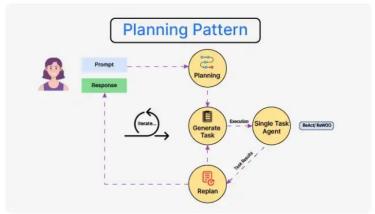
Vztahy mezi agenty

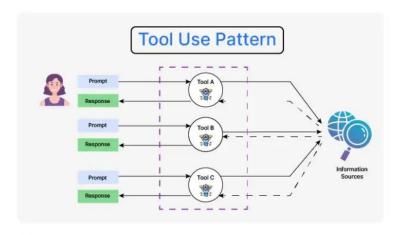


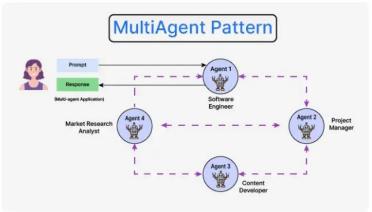
Zdroj: Cheng, et el., Exploring Large Language Model based Intelligent Agents: Definitions, Methods, and Prospects, (arxiv.org)

Návrhové vzory agentních systémů









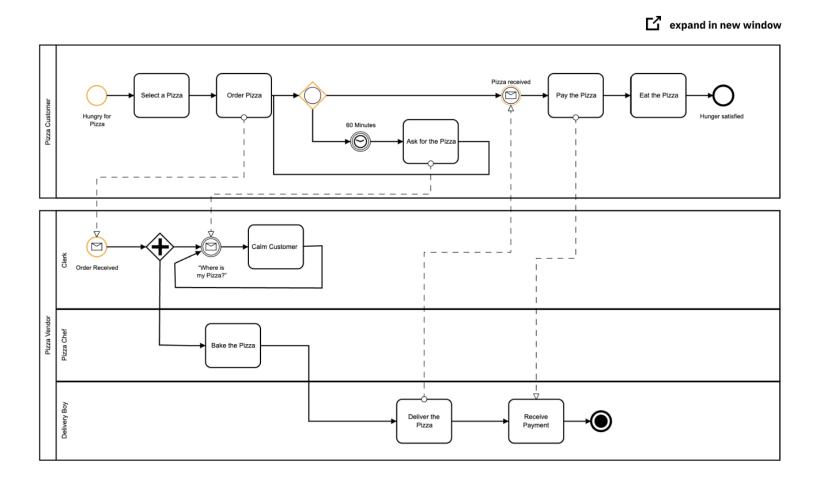
Zdroj: <u>Top 4 Agentic AI Design Patterns - Analytics Vidhya</u>

Business procesy

Business proces

- Posloupnost kroků a operací vedoucích k dosažení cíle.
- Cíle interní nebo vytvoření hodnoty pro zákazníka.
- Prvky procesu:
 - Vstupy zdroje, data, např.
 - Aktivity jednotlivé kroky a operace
 - Výstupy konečná hodnota, produkt
 - Zdroje lidé, technologie, nebo systémy
 - Kontrola ověření a zajištění, že proces funguje správně, zpětná vazba

Business proces - objednání pizzy



Zdroj: <u>BPMN Tutorial: Learn Business Process Model and</u>
Notation | Camunda

Analýza business procesu

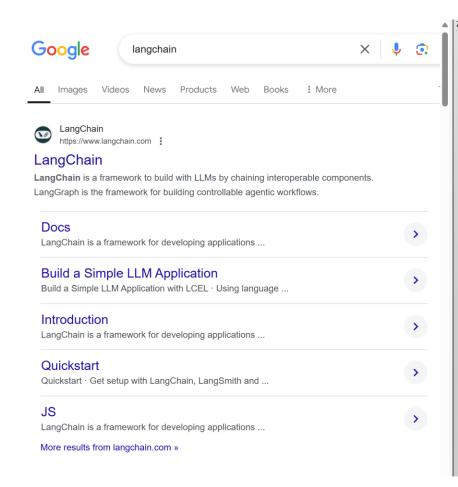
- Chceme zlepšit efektivitu procesu
 - Identifikace opakujících se činností,
 - Automatizace,
 - Snížení nákladů => \$\$\$
- Chceme zjistit, kde nám může Al pomoci:
 - Zpracování faktur,
 - Analýza obrazu,
 - Řízení dodavatelský řetězců,
 - Zákaznická podpora
 - Marketing

LangChain

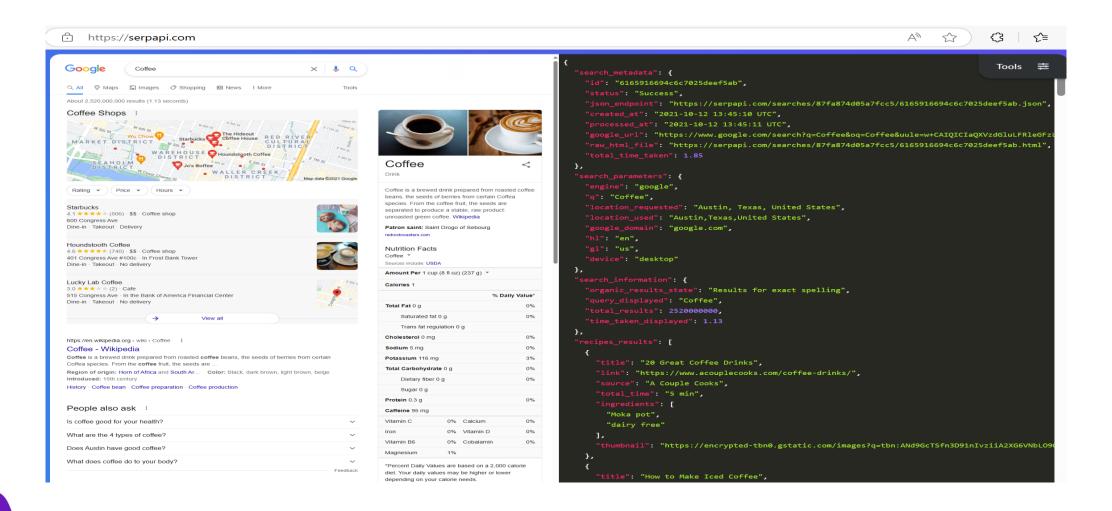
LangChain - historie

- Framework pro práci s velkými jazykovými modely (LLM)
- Představen v roce 2022, původně pro chaining (řetězení) operací
- Abstrakce od konkrétního poskytovatele LLM (ChatGPT, Gemini, Llama, Groq,...)
- Postupně vyvinut pro interakce LLM s externími nástroji a vývoj multiagentních systémů



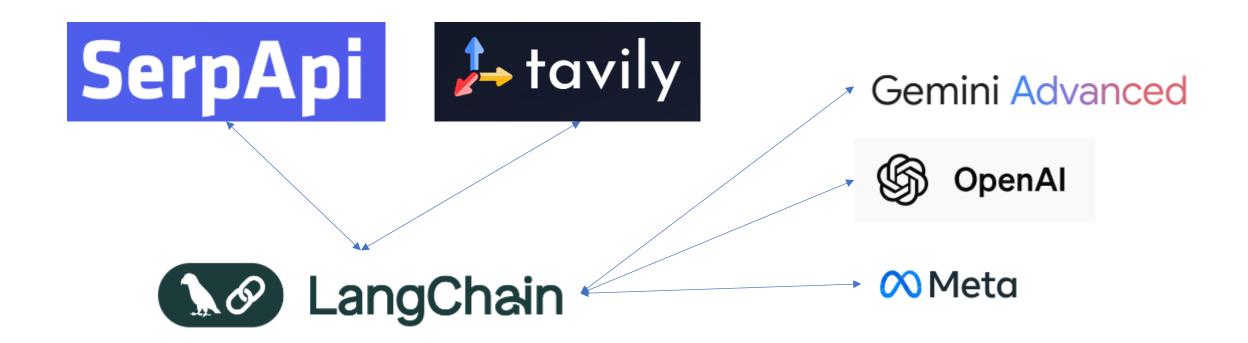


Zalamování řádků 1 <!doctype html><html itemscope="" itemtype="http://schema.org/SearchResultsPage" lang="en 2 var h=this||self;function 1(){return window.google!==void 0&&window.google.kOPI!==void 0& function t(a,b,c,d,k){var e="";b.search("&ei=")===-1&&(e="&ei="+p(d),b.search("&lei=")=== document.documentElement.addEventListener("submit",function(b){var a;if(a=b.target){var c var p=this||self;window.google=window.google||{};var q=window.performance&&window.performa function da(a){return a.style.display==="none"?!0:document.defaultView&&document.defaultV function ea(a,b,c,d,f){var h=f(a),l=h.left+(c?0:window.pageXOffset),m=h.top+(c?0:window.pageXOffset) this.g.complete);(this.A=a)||this.i||D(this);ka&&E(this)},D=function(a){google.rll(a.g,!0 ha&&c.classList.contains("XNfAUb"))break a;c=null}var d=b.parentElement;if(d&&(d.tagName= function N(a){M(a.timeStamp)&&A(document,"visibilitychange",N,!0)}google.c.fh=Infinity;z(function R(a){var b=google.timers.load,c=b.m;if(!c||!c.prs){c=window._csc==="agsa"&&window a.push(["cshid",p._cshid]);b=window.google!==void 0&&window.google.kOPI!==void 0&&window. 13 c[0];break a}c=void 0}c&&(g=c.deliveryType,typeof g==="string"&&(a+="&dt="+g),c=c.transfe function e(c,d){for(var b=f,a=0;a<c.length;a++){var g=c[a];(d?b.etc:b.et).push(g);b.c.add function b(c){var a;a:{for(a=c.target;a&a!==document.documentElement;a=a.parentElement)i var b=this||self;var d,e;a:{for(var f=["CLOSURE_FLAGS"],g=b,h=0;h<f.length;h++)if(g=g[f[h</pre> 17 var g=this||self;var k,l=(k=g.mei)!=null?k:1,n,p=(n=g.sdo)!=null?n:!0,q=0,r,t=google.erd, 18 "&bver="+b(t.bv);t.dpf&&(c+="&dpf="+b(t.dpf));var f=a.lineNumber;f!==void 0&&(c+="&line="-19 "&uap="+a(b.platform));b.platformVersion&&(c+="&uapv="+a(b.platformVersion));b.uaFullVers 20 var p=/^\s*(?!javascript:)(?:[\w+.-]+:|[^:/?#]*(?:[/?#]|\$))/i; 21 var q=/#|\$/;var r=function(){var b={H:google.eufsv},a=this;b=(b===void 0?{}:b).H;this.g=n 22 (a={i:this.g},a=new h({url:c,i:(a===void 0?{}:a).i}),a.s&&a.j||a.v?a.G?(fetch(m(a,1),{metl| function v(b,a){b=b.href;var c=/[?&]nis=([^&]*)/.exec(b);return c&&c[1]===a?b:c?b.replace 24 var c=this||self;function d(a){return a?a.closest("A"):null}function e(a){if(a=d(a.target 25 </script><style>html,body,h1,input,select{font-family:Arial,sans-serif}body,h1{font-size: 26 var a=this||self;var c=document.querySelector("form");if(c){var d=function(b){b.key!=="En 27 </script><style>.y3NyWc{position:absolute;left:0;right:0;top:0}.y3NyWc{width:calc(var(--c google.c.setup(c.g);var n=void 0;d=((n=google.c)==null?void 0:n.wh)>1&&a!=null&&a&1;a=void google.c.setup(c.g); var n=void 0;d=((n=google.c)==null?void 0:n.wh)>1&&a!=null&&a&1;a=void google.c.setup(c.g); var n=void 0;d=((n=google.c)==null?void 0:n.wh)>1&&a!=null&&a&1;a=void 31 c))break a;c=c[g]}a=a[a.length-1];d=c[a];b=b(d);b!=d&&b!=null&&e(c,a,{configurable:!0,wri 32 var l=this||self;function m(){var a,b,c;if(b=a=(b=window.google)==null?void 0:(c=b.ia)==n var n=globalThis.trustedTypes,p;function q(){var a=null;if(!n)return a;try{var b=function s4 function E(){var a=[u];if(!google.dp){for(var b=0;b<a.length;b++){var c=z("LINK"),d=A(a[b]</pre> 35 var e=this||self;var g,h;a:{for(var k=["CLOSURE FLAGS"],l=e,n=0;n<k.length;n++)if(l=1[k[n a.closest("[data-ved]"))?D(f)||"":"";f=f||"";if(a.hasAttribute("jsname"))a=a.getAttribute 37 k:"Missing ID"),!1,d)}}catch(x){google.ml(x,!0,{"jsl.dh":!0})}};(function(){var x=true;go 38 (this||self).Bqpk9e=function(f,d,n,e,k,p){var g=document.getElementById(f);if(g&&(g.offse 39 RegExp("\\btHT01\\b"),k=RegExp("\\bpQXcHc\\b"),b.className=b.className.replace(e,""),c.cla 40 (this||self).Bqpk9e=function(f,d,n,e,k,p){var g=document.getElementById(f);if(g&&(g.offse 41 RegExp("\\btHT01\\b"),k=RegExp("\\bpQXcHc\\b"),b.className=b.className.replace(e,""),c.cli 42 (this||self).Bqpk9e=function(f,d,n,e,k,p){var g=document.getElementById(f);if(g&&(g.offse 43 RegExp("\btHT01\b"),k=RegExp("\bpQXcHc\b"),b.className=b.className.replace(e,""),c.cla



```
"title": "How to Make Iced Coffee",
"link": "https://www.recipegirl.com/how-to-make-iced-coffee/",
"source": "Recipe Girl",
"total_time": "5 min",
"ingredients": [
  "Simple syrup",
  "cream",
  "coffee frozen"
],
"thumbnail": "https://encrypted-tbn0.gstatic.com/images?q=tbn:/
```

• Interakce agentů s externími nástroji a zdroji informací



- Celá řada nástrojů a služeb, které zjednodušují jednotlivé úkony
- Tools | LangChain

Tool/Toolkit	Free/Paid	Return Data
Bing Search	Paid	URL, Snippet, Title
Brave Search	Free	URL, Snippet, Title
DuckDuckgoSearch	Free	URL, Snippet, Title
Exa Search	1000 free searches/month	URL, Author, Title, Published Date
Google Search	Paid	URL, Snippet, Title
Google Serper	Free	URL, Snippet, Title, Search Rank, Site Links

Cena interakce s ChatGPT

- Účetní jednotkou interakce s LLM modely je token
- Služby LLM jsou zpoplatněny na základě spotřebovaných tokenů

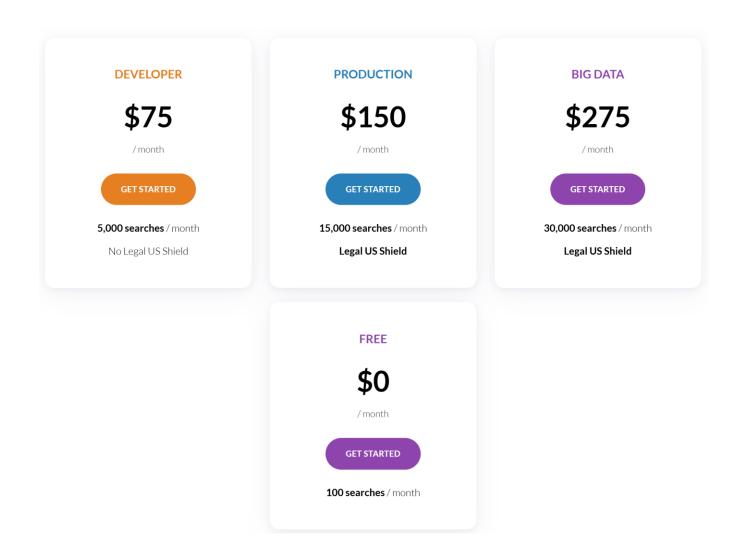
Model	Pricing
gpt-4o	\$2.50 / 1M input tokens
	\$1.25 / 1M cached** input tokens
	\$10.00 / 1M output tokens
gpt-4o-2024-08-06	\$2.50 / 1M input tokens
	\$1.25 / 1M cached** input tokens
	\$10.00 / 1M output tokens

Token – co a za kolik

```
GPT-4o & GPT-4o mini
                     GPT-3.5 & GPT-4
                                      GPT-3 (Legacy)
 Ahoj všem, jak se máte?
         Show example
 Clear
Tokens
           Characters
10
           23
 Ahoj všem, jak se máte?
```

https://platform.openai.com/tokenizer

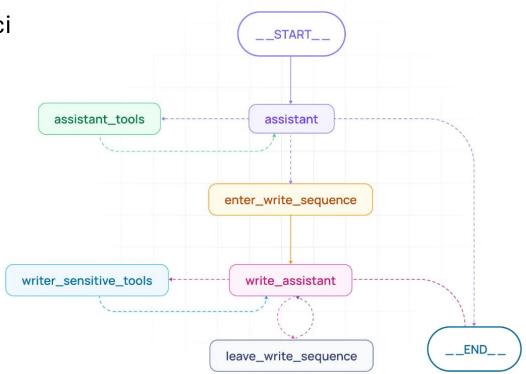
Cena interakce se SerpApi



LangGraph

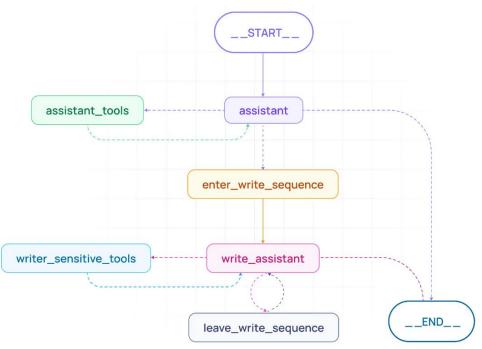
LangGraph

- Framework umožňující vytváření a interakci agentů založených (nejen) na LLM
- Integrován s LangChainem
- Umožňuje cykly a větvení



LangGraph

- Agenti organizování v orientovaném grafu
- Uzly reprezentují agenty
- Hrany reprezentují tok informací mezi agenty, jejich komunikaci
- Počáteční a koncové stavy



LangGraph – stav MAS

- Stav systému popisujeme proměnnými
- Jednotliví agenti MAS modifikují stav systému
- Agenti reagují na základě stavu systému, tj. hodnot proměnných

```
class AgentState(TypedDict):
    variable1: str
    variable2: int
    listVariable: List[int]
```

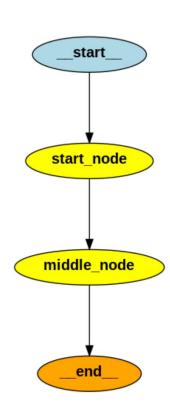
LangGraph – sestavení grafu

Voláním metod add_node a add_edge sestavíme graf multiagentního systému

```
builder = StateGraph(AgentState)
builder.add_node("start_node", start_agent)
builder.add_node("middle_node", middle_agent)

builder.add_edge("start_node", "middle_node")
builder.add_edge("middle_node", END)

builder.set_entry_point("start_node")
graph = builder.compile()
```



LangGraph – agent

Agent je reprezentován funkcí, která obdrží a modifikuje stav multiagentního systému

```
builder.add_node("start_node", start_agent)
                                                                          start
                                                                        start node
def start_agent(state: AgentState):
    messages = [
        SystemMessage(content="Jsi milý, komunikační asistent."),
        HumanMessage(content="Ahoj."),
                                                                       middle node
    response = model.invoke(messages)
    return {"response": response.content}
```

LangGraph – ChatGPT

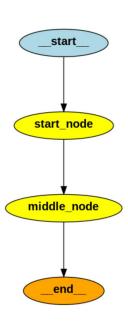
- Připojení vlastním OpenAl API klíčem.
- Řešíme přes <u>platform.openai.com</u>

```
import os
from langchain_openai import ChatOpenAI
model = ChatOpenAI(model="gpt-4o,
    openai_api_key=os.environ["OPENAI_PRIVATE_API_KEY"])
...
model.invoke(messages)
model.with_structured_output(Structured).invoke(messages)
```

LangGraph – spuštění

- Postupný průchod grafem pomocí graph.stream metody
- Každý průchod grafem může mít přiřazeno unikátní id, abychom mohli vést více konverzací zároveň

```
thread = {"configurable": {"thread_id": "1"}}
state = None
for s in graph.stream({
    'msg': "Ahoj světe!"
}, thread):
    state = s
```



Praktická ukázka

Emaily

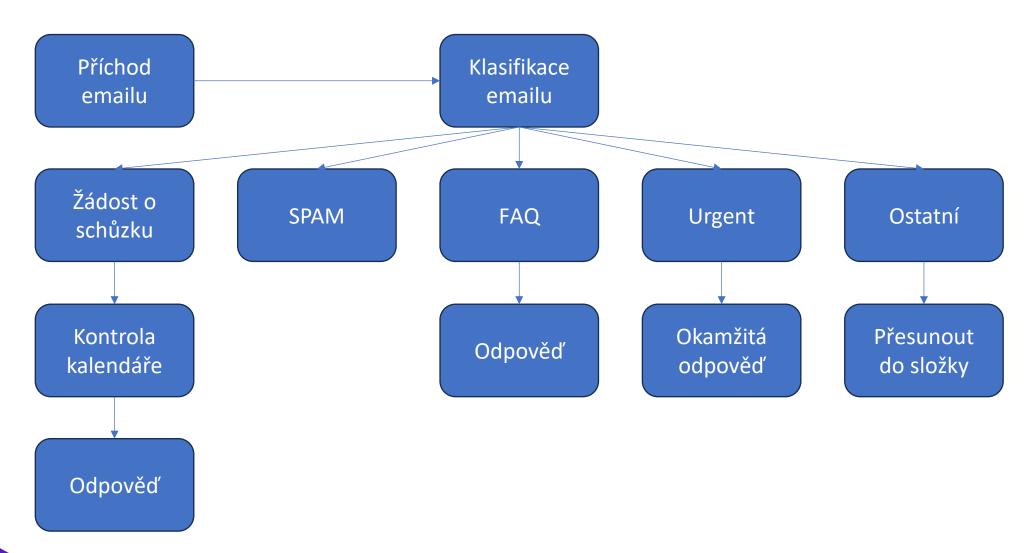


DALL-E: Vytvoř obrázek pro moji prezentaci, na obrázku by mělo být vystihnuto, že se uživatel může zbláznit z množství emailů, které mu denně dojdou.

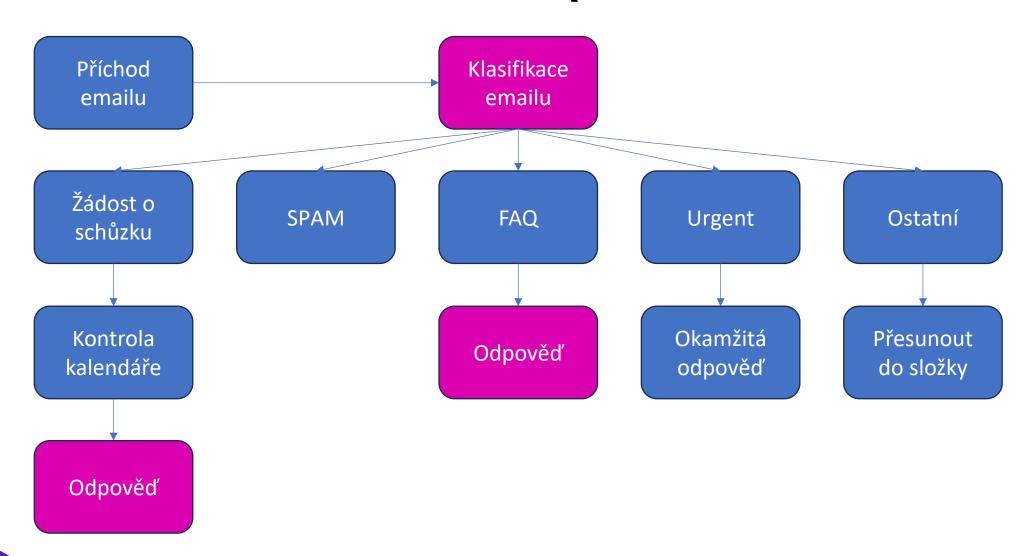
Ředitelé mají asisten-ty/tky

- Zpracování emailu aktivita, kterou řešíme všichni každý den
- Jak a kdy reagujeme na emaily?
 - Mají nějaké emaily prioritu, čím jsou charakteristické
- Existuje skupina emailů, které nepotřebují mou interakci?
 - Dají se zodpovědět beze mě => automatizace
- Jsou emaily, k jejichž zodpovězení stačí databáze znalostí?
 - Retrieval augmented generation (RAG)
- Je email nositelem zajímavé informace?
 - Nezahazovat, ale zobrazit/přesunout do složky "zajímavé"

Business proces – zpracování emailu



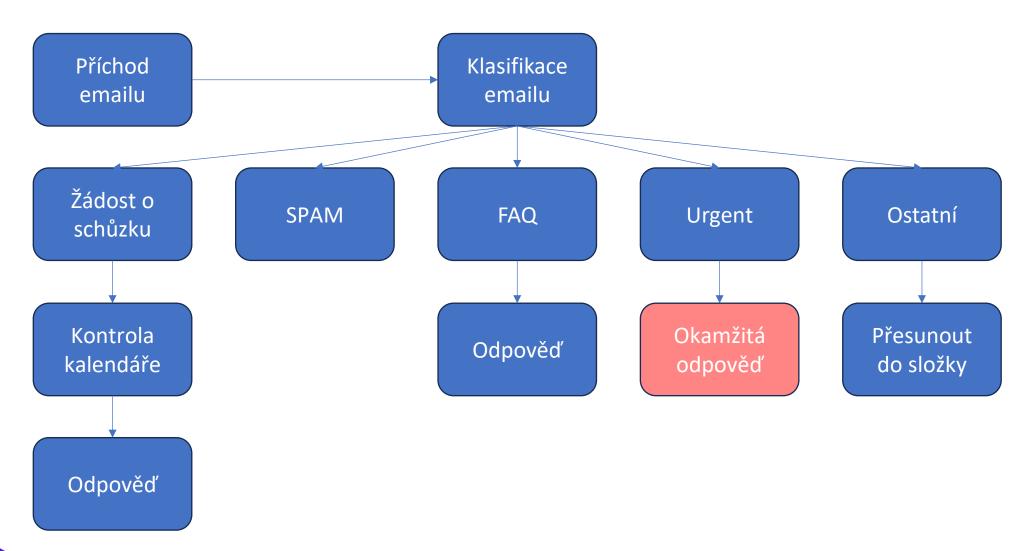
Kde můžeme použít Al



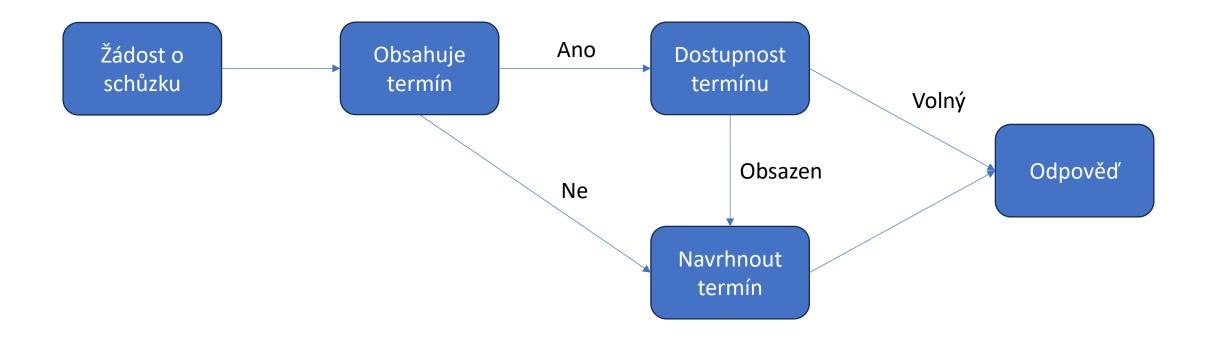
Agenti



Business proces – human agent



Business proces – zpracování emailu



Klasifikátor

```
MAIL CLASSIFY PROMPT =
Jsi asistent, který je expertem na klasifikaci e-mailů podle obsahu. \
Klasifikuj e-mail do jedné z následujících kategorií dle jejich popisků. \
Zároveň se podívej, zda e-mail obsahuje nějakou otázku, která by mohla být v FAQ. \
Email: \
{email} \
Kategorie: \
{categories} \
FAQ: \
{faq} \
11 11 11
```

Asistent - schůzky

```
RESPONSE MEETING PROMPT =
Jsi asistent, který odpovídá na e-maily na domluvení schůzky. \
Napiš odpověď na následující email: \
Email: \
{email} \
Pokud je schůzka možná dle volných termínů, napiš, že je možné se sejít. \
Pokud schůzka neodpovídá volným termínům, navrhni vhodné volné termíny. Dle níže uvedených
volných termínů. \
Volné termíny: \
{free times}
11 11 11
```

Few shot prompt

 Dáme klasifikátoru příklady nebo popisky pro předvolené kategorie

```
MAIL_CATEGORY = {
    ("SPAM", "Nevyžádaná pošta, nevyžádané nabídky, phishingové
emaily."),
    ("FAQ", "Často kladené otázky."),
    ("MEETING", "Email s žádostí o schůzku."),
    ("URGENT", "Email vyžadující okamžitou odpověď."),
    ("OTHER", "Ostatní emaily."),
}
```

Retrieval Augmented Generation

- Doplníme chatbota o externí zdroje informací
- Databáze, dokumenty, webové stránky

```
FAQ = [
    ("Lze dopsat test, pokud jsem byl nemocný?", "Ano, lze na dalším
cvičení."),
    ("Jaké máte termíny konzultací?", "Konzultace probíhají vždy ve
středu od 14:00 do 16:00."),
    ("Jaké je heslo k Wi-Fi?", "Heslo k Wi-Fi je '12345678'."),
]
```

Napojení externích služeb

- Můžeme připojit k externích službám např. kalendář
- Interakce s kalendářem v rukou programátora, bez Al

```
FREE_TIMES = [
    ("pondělí", "12:30"),
    ("úterý", "14:00"),
    ("středa", "16:00"),
    ("čtvrtek", "10:00"),
    ("pátek", "8:00"),
```

Reflexe – zpětná vazba

• Agent, který má za úkol verifikovat odpověď systému

```
MAIL_REVIEW_PROMPT = """
Jsi expertem na psaní textů. Zkontroluj odpověď na email, zda je
gramaticky správně, \
zda odpovídá na otázku, zda je slušná a formální a zda je vhodná
pro odeslání. Pokud \
není v pořádku, navrhni připomínky. \

Původní Email:
{email} \
Odpověď:
{response} \
"""
```

Excesy

- Detailní zpracování procesu nám může pomoci eliminovat chyby
- Pracuji v Ostravě, co když chatbot tuto informaci nemá:

```
11 11 11
                                             11 11 11
Dobrý den,
                                            Dobrý den pane Nováku,
tento týden jsem v Praze,
                                            děkuji za Váš e-mail. Schůzka na
můžeme se sejít na konzultaci
                                            Staroměstském náměstí v pondělí
na Staroměstském náměstí
                                            ve 12:30 je možná. Těším se na
                                            setkání s Vámi.
v pondělí ve 12:30?
S pozdravem,
                                            S pozdravem,
Jan Novák
11 11 11
                                             [Vaše jméno]
                                             11 11 11
```

Graf systému

```
builder = StateGraph(AgentState)
builder.add_node("classifier", classifier_node)
builder.add_node("responder", response_node)

builder.add_edge("classifier", "responder")
builder.add_edge("responder", END)

builder.set_entry_point("classifier")
graph = builder.compile(checkpointer=memory)
```

Stav systému

- Stav systému zachycen ve třech proměnných
- Reprezentace vstupního emailu, detekovaná kategorie a vygenerovaná odpověď

```
class AgentState(TypedDict):
    email: str
    category: str
    response: str
```

Klasifikační agent

```
def classifier_node(state: AgentState):
    categories = [name + "-" + description for name, description in MAIL_CATEGORY]
    messages = [
        SystemMessage(content=MAIL_CLASSIFY_PROMPT.format(email=state["email"],
        categories=", ".join(categories), faq=", ".join([q for q, a in FAQ]))),
        HumanMessage(content="Přiřaď e-mail do kategorie."),
    ]
    category = model.with_structured_output(Category).invoke(messages)
    return {"category": category.name}
```

Odpovídající agent

```
def response_node(state: AgentState):
    if state["category"] == "MEETING":
       messages = [
            SystemMessage(content=RESPONSE_MEETING_PROMPT.format(email=state["email"],
free_times=", ".join([f"{day} v {time}" for day, time in FREE_TIMES]))),
           HumanMessage(content="Napis odpoved na e-mail:"),
        response = model.invoke(messages)
    else:
        response = "Děkuji za e-mail. Odpovím co nejdříve to bude možné."
    return {"response": response}
```



Díky za pozornost. Otázky či diskuze!?

github.com/mvasinek







